

# A Relevância da Mecânica Clássica na Era da Inteligência Artificial Generativa

Aula Magna – Concurso para Professor Titular

Candidato

Departamento de Biofísica e Farmacologia  
Instituto de Biociências  
UNESP Botucatu

15 de junho de 2026

*“Se vi mais longe, foi por estar sobre ombros de gigantes.”*

— Isaac Newton, 1675

# Roteiro

1. Introdução Filosófica
2. Fundamentos da Mecânica Clássica
3. Inteligência Artificial Generativa
4. Pontes Conceituais
5. Implicações Filosóficas
6. Conclusão

## O que significa “compreender” a natureza?

### Compreensão Analítica


- Leis fundamentais
- Relações causais
- Dedução matemática
- **Por que** acontece

### Compreensão Estatística

- Padrões nos dados
- Correlações
- Inferência probabilística
- **O que** acontece


# Modelos Analíticos vs. Modelos Estatísticos

## Abordagem Analítica



Complementares?  
←-----→

## Abordagem Estatística



# Duas Tradições de Conhecimento

## Tradição Analítica (Top-Down)

- Princípios primeiros
- Dedução rigorosa
- Leis universais
- Determinismo

**Mecânica Clássica**


## Tradição Empírica (Bottom-Up)

- Dados observados
- Indução estatística
- Padrões locais
- Probabilismo

**IA Generativa**

*Ambas buscam modelos preditivos da realidade*

# Paralelo Histórico



*Dois paradigmas de formalização do conhecimento sobre a natureza*

# A Revolução Newtoniana

## As Três Leis de Newton

### 1ª Lei (Inércia):

$$\vec{F} = 0 \Rightarrow \vec{v} = \text{constante}$$

### 2ª Lei (Dinâmica):

$$\vec{F} = m\vec{a} = m \frac{d^2 \vec{r}}{dt^2}$$

### 3ª Lei (Ação e Reação):

$$\vec{F}_{12} = -\vec{F}_{21}$$

## Paradigma de Simplicidade

- Três leis
- Poder explicativo universal
- Matematização da natureza

## Gravitação Universal

$$F = G \frac{m_1 m_2}{r^2}$$



# O Determinismo Laplaciano

*“Uma inteligência que, em um dado instante, conhecesse todas as forças que animam a natureza e a situação de cada ser que a compõe [...] nada seria incerto para ela, e o futuro, como o passado, estaria presente aos seus olhos.”*

— Pierre-Simon Laplace, 1814

## Implicações Filosóficas

- Conhecendo  $\vec{r}(t_0)$  e  $\vec{v}(t_0) \Rightarrow$  conhecemos  $\vec{r}(t)$  para todo  $t$
- O universo como um relógio mecânico
- Previsibilidade total em princípio

## Princípio de Mínima Ação (Hamilton)

$$\delta S = \delta \int_{t_1}^{t_2} L(q, \dot{q}, t) dt = 0$$

Lagrangiana:

$$L = T - V$$

Equações de Euler-Lagrange:

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} = 0$$

## Vantagens

- Coordenadas generalizadas
- Invariância por transformações
- Elegância matemática
- Conexão com simetrias

Hamiltoniana:

$$H(q, p, t) = \sum_i p_i \dot{q}_i - L$$

Equações Canônicas:

$$\dot{q}_i = \frac{\partial H}{\partial p_i}$$

$$\dot{p}_i = -\frac{\partial H}{\partial q_i}$$

## Espaço de Fase

- Espaço  $(q, p)$  de  $2n$  dimensões
- Trajetórias determinísticas
- Fluxo hamiltoniano
- Base para Mecânica Quântica

## Conservação

$$\frac{dH}{dt} = \frac{\partial H}{\partial t}$$

# Problema dos Dois Corpos

## Solução Analítica Exata


Redução ao problema de um corpo:

$$\mu = \frac{m_1 m_2}{m_1 + m_2}$$

Órbitas cônicas:

$$r(\theta) = \frac{p}{1 + e \cos \theta}$$

Leis de Kepler derivadas matematicamente




*Triunfo da mecânica newtoniana*

# Problema dos Três Corpos

## Sem Solução Analítica Geral

- Poincaré (1890): demonstrou a inexistência de solução geral
- Sensibilidade às condições iniciais
- Nascimento da teoria do caos



*Limites da previsibilidade*

## Caos Determinístico:

- Equações determinísticas
- Comportamento imprevisível
- Expoentes de Lyapunov

# Do Determinismo ao Caos

## Sensibilidade às Condições Iniciais

Pequenas diferenças iniciais  $\Rightarrow$  grandes divergências

$$|\delta \vec{r}(t)| \sim |\delta \vec{r}(0)| e^{\lambda t}$$

onde  $\lambda > 0$  é o expoente de Lyapunov

## Teorema KAM

Kolmogorov-Arnold-Moser (1954-1963)

- Estabilidade parcial
- Toros invariantes
- Ilhas de regularidade

## Implicação

*Mesmo sistemas determinísticos têm horizonte de previsibilidade finito*

## Paradigma da IA: Aprendizado a partir de Padrões

### IA Simbólica (Clássica)

- Regras explícitas
- Conhecimento codificado
- Raciocínio dedutivo
- “GOFAI”

### IA Conexionista (Moderna)

- Padrões aprendidos
- Conhecimento distribuído
- Inferência estatística
- Redes neurais profundas

*Mudança epistemológica fundamental*


# Redes Neurais: Representação Distribuída

Neurônio Artificial:

$$y = \sigma \left( \sum_i w_i x_i + b \right)$$

Aprendizado:

$$w \leftarrow w - \eta \frac{\partial \mathcal{L}}{\partial w}$$



## Características

- Milhões/bilhões de parâmetros
- Representações emergentes
- Aproximadores universais



# Arquitetura Transformer

## Mecanismo de Atenção:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

## Inovações

- Self-attention: contexto global
- Paralelização eficiente
- Escalabilidade
- Transferência de aprendizado

## LLMs

### Large Language Models

- GPT, Claude, Gemini
- $10^{11}$  parâmetros
- Treinados em terabytes
- Capacidades emergentes

*Vaswani et al., "Attention Is All You Need", 2017*


# Espaços Latentes: Geometria Oculta

## Representações Aprendidas

- Dados  $\rightarrow$  espaço de alta dimensão
- Estrutura geométrica significativa
- Operações algébricas com sentido

### Exemplo (Word2Vec):

$$\vec{rei} - \vec{homem} + \vec{mulher} \approx \vec{rainha}$$



*Geometria com semântica*

## O Dilema da “Caixa Preta”

### O que a IA faz bem

- Reconhecer padrões
- Gerar conteúdo coerente
- Interpolar entre exemplos
- Generalizar estatisticamente

### Limitações

- Não “compreende” causalmente
- Alucinações
- Raciocínio lógico limitado
- Interpretabilidade restrita

*“Stochastic parrots” vs. compreensão genuína?*

# Princípios Variacionais: Conexão Profunda

## Mecânica Clássica

**Princípio de Mínima Ação:**

$$\delta S = \delta \int L dt = 0$$

A natureza “escolhe” o caminho que extremiza a ação

## Redes Neurais

**Minimização da Loss:**

$$\min_{\theta} \mathcal{L}(\theta) = \min_{\theta} \sum_i \ell(f_{\theta}(x_i), y_i)$$

O modelo “escolhe” parâmetros que minimizam o erro

## Princípio Unificador

Otimização como linguagem comum

# Gradiente Descendente e Cálculo de Variações

## Cálculo de Variações:


$$\frac{\delta F}{\delta y} = \frac{\partial f}{\partial y} - \frac{d}{dx} \frac{\partial f}{\partial y'}$$

Encontra funções que extremizam funcionais

## Gradiente Descendente:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}$$

Encontra parâmetros que minimizam funções



# Princípio da Energia Livre (Friston)

## Framework Unificador

Sistemas adaptativos minimizam **energia livre variacional**:

$$F = D_{KL}[q(\theta) \| p(\theta|x)] - \log p(x)$$

### Aplicações:

- Neurociência computacional
- Percepção ativa
- Controle motor
- Aprendizado de máquina

### Conexões:

- Inferência Bayesiana
- Termodinâmica
- Mecânica estatística
- Princípio de mínima ação

*Friston et al., Physics Reports, 2023*

## Physics-Informed Neural Networks (PINNs)

$$\mathcal{L} = \mathcal{L}_{\text{dados}} + \lambda \mathcal{L}_{\text{física}}$$

Rede neural treinada para satisfazer EDPs

### Vantagens:

- Sem malha (mesh-free)
- Alta dimensionalidade
- Dados escassos
- Problemas inversos

### Aplicações:

- Dinâmica de fluidos
- Mecânica quântica
- Propagação de ondas
- Relatividade geral

*Karniadakis et al., Nature Reviews Physics, 2021*

## SINDy: Sparse Identification of Nonlinear Dynamics

$$\dot{x} = \Theta(x) \xi$$

onde  $\Theta$  é uma biblioteca de funções candidatas e  $\xi$  são coeficientes esparsos

### Exemplos de Sucesso:

- Redescoberta de leis de Kepler
- Identificação de Hamiltonianos
- Leis de conservação
- Simetrias ocultas

### Questão Filosófica

*A IA “compreende” as leis que descobre?*

*Brunton et al., PNAS, 2016*



## Lagrangian Neural Networks

$$\frac{d}{dt} \frac{\partial \mathcal{L}_\theta}{\partial \dot{q}} = \frac{\partial \mathcal{L}_\theta}{\partial q}$$

Redes que respeitam estrutura lagrangiana

## Hamiltonian Neural Networks

$$\begin{aligned}\dot{q} &= \frac{\partial H_\theta}{\partial p} \\ \dot{p} &= -\frac{\partial H_\theta}{\partial q}\end{aligned}$$

## Vantagens:

- Conservação de energia garantida
- Estabilidade de longo prazo
- Extrapolação confiável
- Interpretabilidade física

*O melhor dos dois mundos: aprendizado com estrutura física*

# Complementaridade Epistemológica

|               | Mecânica Clássica | IA Generativa        |
|---------------|-------------------|----------------------|
| Abordagem     | Top-down          | Bottom-up            |
| Raciocínio    | Dedutivo          | Indutivo             |
| Conhecimento  | Leis fundamentais | Padrões nos dados    |
| Objetivo      | Explicação causal | Predição estatística |
| Transparência | Alta              | Baixa                |
| Generalização | Por princípios    | Por interpolação     |

**Tese Central**

**Não são excludentes, mas complementares**

# Explicação vs. Predição

## Explicação Causal

- Por que o fenômeno ocorre?
- Mecanismos subjacentes
- Compreensão profunda
- Transferível entre contextos

*“A maçã cai porque a gravidade atrai”*


## Predição Estatística

- O que vai acontecer?
- Correlações observadas
- Precisão prática
- Contexto-dependente

*“Historicamente, maçãs caem”*

**Ambas são formas válidas de conhecimento científico**

# Hibridização: O Melhor dos Dois Mundos



## Exemplos

- Neural ODEs com estrutura hamiltoniana
- PINNs para problemas inversos
- Graph Neural Networks para simulações físicas

## Desafio da Interpretabilidade

Como tornar modelos de IA mais compreensíveis?

### Princípios da Física:

- Leis de conservação
- Simetrias
- Localidade
- Causalidade

### Aplicações em IA:

- Equivariant NNs
- Conservation laws constraints
- Causal representation learning
- Physics-guided architectures

*A física como fonte de princípios reguladores para IA*

## O Futuro da Física na Era da IA

- ❶ **Descoberta assistida por IA**
  - Identificação de padrões em dados massivos
  - Sugestão de hipóteses a serem testadas
- ❷ **Simulação acelerada**
  - Emuladores neurais de simulações físicas
  - Exploração de espaços de parâmetros
- ❸ **Síntese de conhecimento**
  - Integração de dados heterogêneos
  - Conexões entre áreas distintas

*O físico como integrador de paradigmas*

# A Permanente Relevância da Mecânica Clássica

## Fundamento Conceitual

- Base de toda física moderna
- Linguagem matemática universal
- Paradigma de rigor científico
- Framework para novos desenvolvimentos

## Relevância Contemporânea

- Engenharia e tecnologia
- Astrofísica e cosmologia
- Biofísica e sistemas complexos
- Inspiração para algoritmos

## Mensagem Central

*A Mecânica Clássica não é obsoleta  
— é fundamental e atemporal*

*“A mecânica de Newton é  
ainda a física que mais se  
usa.”*

— Feynman

# Mecânica Clássica na Era Digital

## Inspiração para IA


- Arquiteturas baseadas em física
- Princípios variacionais
- Leis de conservação
- Simetrias como inductive bias

## Benchmark para IA

- Validação de modelos
- Ground truth analítico
- Teste de extrapolação
- Avaliação de interpretabilidade

**A Mecânica Clássica como pedra de toque para a era da IA**





Diferentes formas de conhecimento não são  
excludentes

A ciência avança pela pluralidade metodológica

O físico contemporâneo: integrador de paradigmas

A Mecânica Clássica permanece relevante não *apesar* da IA, mas *junto* com ela —  
como instrumento complementar na busca pela compreensão da natureza.

# Obrigado

Perguntas?

*“O objetivo da física é descobrir as leis que a natureza escolheu, não as leis que nós gostaríamos que ela tivesse escolhido.”*

— Richard Feynman

## Mecânica Clássica

- GOLDSTEIN, H. *Classical Mechanics*. 2nd ed. Addison Wesley, 2002.
- LANDAU, L. D.; LIFSHITZ, E. M. *Mechanics*. 3rd ed. Butterworth-Heinemann, 1976.
- ARNOLD, V. I. *Mathematical Methods of Classical Mechanics*. Springer, 1989.

# Referências Seleccionadas II

## IA e Aprendizado de Máquina

- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- VASWANI, A. et al. Attention Is All You Need. *NeurIPS*, 2017.

## Conexões Física-IA

- KARNIADAKIS, G. E. et al. Physics-informed machine learning. *Nature Reviews Physics*, v. 3, p. 422-440, 2021.
- BRUNTON, S. L. et al. Discovering governing equations from data. *PNAS*, v. 113, n. 15, p. 3932-3937, 2016.
- FRISTON, K. et al. The free energy principle made simpler. *Physics Reports*, v. 1024, p. 1-29, 2023.
- CRANMER, M. D. et al. Lagrangian Neural Networks. *ICLR Workshop*, 2020.