

A Relevância da Mecânica Clássica na Era da Inteligência Artificial Generativa

Aula Magna – Concurso para Professor Titular

Candidato

Departamento de Biofísica e Farmacologia
Instituto de Biociências
UNESP Botucatu

15 de junho de 2026

“Se vi mais longe, foi por estar sobre ombros de gigantes.”

— Isaac Newton, 1675

Roteiro

1. Introdução Filosófica
2. Fundamentos da Mecânica Clássica
3. Inteligência Artificial Generativa
4. Pontes Conceituais
5. Implicações Filosóficas
6. Conclusão

O que significa “compreender” a natureza?

Compreensão Analítica


- Leis fundamentais
- Relações causais
- Dedução matemática
- **Por que** acontece

Compreensão Estatística

- Padrões nos dados
- Correlações
- Inferência probabilística
- **O que** acontece


Modelos Analíticos vs. Modelos Estatísticos

Abordagem Analítica



Complementares?
←-----→

Abordagem Estatística



Duas Tradições de Conhecimento

Tradição Analítica (Top-Down)

- Princípios primeiros
- Dedução rigorosa
- Leis universais
- Determinismo

Mecânica Clássica


Tradição Empírica (Bottom-Up)

- Dados observados
- Indução estatística
- Padrões locais
- Probabilismo

IA Generativa

Ambas buscam modelos preditivos da realidade

Paralelo Histórico



Dois paradigmas de formalização do conhecimento sobre a natureza

A Revolução Newtoniana

As Três Leis de Newton

1ª Lei (Inércia):

$$\vec{F} = 0 \Rightarrow \vec{v} = \text{constante}$$

2ª Lei (Dinâmica):

$$\vec{F} = m\vec{a} = m \frac{d^2 \vec{r}}{dt^2}$$

3ª Lei (Ação e Reação):

$$\vec{F}_{12} = -\vec{F}_{21}$$

Paradigma de Simplicidade

- Três leis
- Poder explicativo universal
- Matematização da natureza

Gravitação Universal

$$F = G \frac{m_1 m_2}{r^2}$$

O Determinismo Laplaciano

“Uma inteligência que, em um dado instante, conhecesse todas as forças que animam a natureza e a situação de cada ser que a compõe [...] nada seria incerto para ela, e o futuro, como o passado, estaria presente aos seus olhos.”

— Pierre-Simon Laplace, 1814

Implicações Filosóficas

- Conhecendo $\vec{r}(t_0)$ e $\vec{v}(t_0) \Rightarrow$ conhecemos $\vec{r}(t)$ para todo t
- O universo como um relógio mecânico
- Previsibilidade total em princípio

Princípio de Mínima Ação (Hamilton)

$$\delta S = \delta \int_{t_1}^{t_2} L(q, \dot{q}, t) dt = 0$$

Lagrangiana:

$$L = T - V$$

Equações de Euler-Lagrange:

$$\frac{d}{dt} \frac{\partial L}{\partial \dot{q}_i} - \frac{\partial L}{\partial q_i} = 0$$

Vantagens

- Coordenadas generalizadas
- Invariância por transformações
- Elegância matemática
- Conexão com simetrias

Hamiltoniana:

$$H(q, p, t) = \sum_i p_i \dot{q}_i - L$$

Equações Canônicas:

$$\dot{q}_i = \frac{\partial H}{\partial p_i}$$

$$\dot{p}_i = -\frac{\partial H}{\partial q_i}$$

Espaço de Fase

- Espaço (q, p) de $2n$ dimensões
- Trajetórias determinísticas
- Fluxo hamiltoniano
- Base para Mecânica Quântica

Conservação

$$\frac{dH}{dt} = \frac{\partial H}{\partial t}$$

Problema dos Dois Corpos

Solução Analítica Exata


Redução ao problema de um corpo:

$$\mu = \frac{m_1 m_2}{m_1 + m_2}$$

Órbitas cônicas:

$$r(\theta) = \frac{p}{1 + e \cos \theta}$$

Leis de Kepler derivadas matematicamente




Triunfo da mecânica newtoniana

Problema dos Três Corpos

Sem Solução Analítica Geral

- Poincaré (1890): demonstrou a inexistência de solução geral
- Sensibilidade às condições iniciais
- Nascimento da teoria do caos



Limites da previsibilidade

Caos Determinístico:

- Equações determinísticas
- Comportamento imprevisível
- Expoentes de Lyapunov

Do Determinismo ao Caos

Resultado Fundamental

Sistemas determinísticos e conservativos podem ser caóticos

Sensibilidade às Condições Iniciais

Pequenas diferenças $\Rightarrow$ grandes divergências

$$|\delta \vec{r}(t)| \sim |\delta \vec{r}(0)| e^{\lambda t}$$

onde $\lambda > 0$ é o expoente de Lyapunov

Teorema KAM

Kolmogorov-Arnold-Moser

- Estabilidade parcial
- Toros invariantes
- Ilhas de regularidade

Mesmo com energia conservada, há **horizonte de previsibilidade finito**

Paradigma da IA: Aprendizado a partir de Padrões

IA Simbólica (Clássica)

- Regras explícitas
- Conhecimento codificado
- Raciocínio dedutivo
- “GOFAI”

IA Conexionista (Moderna)

- Padrões aprendidos
- Conhecimento distribuído
- Inferência estatística
- Redes neurais profundas

Mudança epistemológica fundamental


Redes Neurais: Representação Distribuída

Neurônio Artificial:

$$y = \sigma \left(\sum_i w_i x_i + b \right)$$

Aprendizado (gradiente descendente):

$$w \leftarrow w - \eta \nabla_w \mathcal{L}$$



Características

- Bilhões de parâmetros
- Representações emergentes
- Aproximadores universais

A Grande Ideia: Conhecimento como Geometria

Insight Fundamental

Conceitos e palavras como **pontos em espaços de alta dimensão**:

- **Proximidade** $\approx$ similaridade semântica
- **Direções** $\approx$ relações conceituais
- **Operações vetoriais** $\approx$ raciocínio analógico

Paralelo com a Física

Assim como a Relatividade geometrizou o espaço-tempo, a IA geometriza o *espaço semântico*

Implicação

O significado emerge da **estrutura geométrica**, não de definições explícitas

Espaços Latentes: Geometria Oculta


Representações Aprendidas

- Dados $\rightarrow$ espaço de alta dimensão
- Estrutura geométrica significativa
- Operações algébricas com sentido

Exemplo (Word2Vec):

$$\vec{rei} - \vec{homem} + \vec{mulher} \approx \vec{rainha}$$

Analogias como paralelogramos no espaço vetorial



Geometria com semântica

Arquitetura Transformer

Mecanismo de Atenção:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Inovações

- Self-attention: contexto global
- Paralelização eficiente
- Escalabilidade
- Transferência de aprendizado

LLMs

Large Language Models

- GPT, Claude, Gemini
- 10^{11} parâmetros
- Treinados em terabytes
- Capacidades emergentes

Vaswani et al., "Attention Is All You Need", 2017

O Dilema da “Caixa Preta”

O que a IA faz bem

- Reconhecer padrões
- Gerar conteúdo coerente
- Interpolar entre exemplos
- Generalizar estatisticamente

Limitações

- Não “compreende” causalmente
- Alucinações
- Raciocínio lógico limitado
- Interpretabilidade restrita

“Stochastic parrots” vs. compreensão genuína?

Princípios Variacionais: Conexão Profunda

Mecânica Clássica

Princípio de Mínima Ação:

$$\delta S = \delta \int L dt = 0$$

A natureza “escolhe” o caminho que extremiza a ação

Redes Neurais

Minimização da Loss:

$$\min_{\theta} \mathcal{L}(\theta) = \min_{\theta} \sum_i \ell(f_{\theta}(x_i), y_i)$$

O modelo “escolhe” parâmetros que minimizam o erro

Princípio Unificador

Otimização como linguagem comum

Gradiente Descendente e Cálculo de Variações

Cálculo de Variações:


$$\frac{\delta F}{\delta y} = \frac{\partial f}{\partial y} - \frac{d}{dx} \frac{\partial f}{\partial y'}$$

Encontra funções que extremizam funcionais

Gradiente Descendente:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}$$

Encontra parâmetros que minimizam funções



Princípio da Energia Livre (Friston)

Framework Unificador

Sistemas adaptativos minimizam **energia livre variacional**:

$$F = D_{KL}[q(\theta)||p(\theta|x)] - \log p(x)$$

Aplicações:

- Neurociência computacional
- Percepção ativa
- Controle motor
- Aprendizado de máquina

Conexões:

- Inferência Bayesiana
- Termodinâmica
- Mecânica estatística
- Princípio de mínima ação

Friston et al., Physics Reports, 2023

Physics-Informed Neural Networks (PINNs)

$$\mathcal{L} = \mathcal{L}_{\text{dados}} + \lambda \mathcal{L}_{\text{física}}$$

Rede neural treinada para satisfazer EDPs

Vantagens:

- Sem malha (mesh-free)
- Alta dimensionalidade
- Dados escassos
- Problemas inversos

Aplicações:

- Dinâmica de fluidos
- Mecânica quântica
- Propagação de ondas
- Relatividade geral

Karniadakis et al., Nature Reviews Physics, 2021

SINDy: Sparse Identification of Nonlinear Dynamics

$$\dot{x} = \Theta(x) \xi$$

onde Θ é uma biblioteca de funções candidatas e ξ são coeficientes esparsos

Exemplos de Sucesso:

- Redescoberta de leis de Kepler
- Identificação de Hamiltonianos
- Leis de conservação
- Simetrias ocultas

Questão Filosófica

A IA “compreende” as leis que descobre?

Brunton et al., PNAS, 2016

Lagrangian Neural Networks

$$\frac{d}{dt} \frac{\partial \mathcal{L}_\theta}{\partial \dot{q}} = \frac{\partial \mathcal{L}_\theta}{\partial q}$$

Hamiltonian Neural Networks

$$\dot{q} = \frac{\partial H_\theta}{\partial p}, \quad \dot{p} = -\frac{\partial H_\theta}{\partial q}$$

Vantagens:

- Conservação de energia garantida
- Estabilidade de longo prazo
- Extrapolação confiável
- Interpretabilidade física

O melhor dos dois mundos: aprendizado com estrutura física

Cranmer et al., ICLR Workshop, 2020

Neural ODEs: Dinâmica Contínua Aprendida

Ideia Central

Camadas ocultas como **evolução temporal contínua**:

$$\frac{dh}{dt} = f_{\theta}(h(t), t)$$

Estado final obtido por integração numérica

Conexão com Física

A rede neural define um **campo vetorial** no espaço de estados — análogo a um sistema dinâmico

Vantagens:

- Profundidade adaptativa
- Memória eficiente
- Séries temporais irregulares
- Fluxos normalizantes contínuos

Chen et al., NeurIPS, 2018

Complementaridade Epistemológica

	Mecânica Clássica	IA Generativa
Abordagem	Top-down	Bottom-up
Raciocínio	Dedutivo	Indutivo
Conhecimento	Leis fundamentais	Padrões nos dados
Objetivo	Explicação causal	Predição estatística
Transparência	Alta	Baixa
Generalização	Por princípios	Por interpolação

Tese Central

Não são excludentes, mas complementares

Explicação vs. Predição

Explicação Causal

- Por que o fenômeno ocorre?
- Mecanismos subjacentes
- Compreensão profunda
- Transferível entre contextos

“A maçã cai porque a gravidade atrai”


Predição Estatística

- O que vai acontecer?
- Correlações observadas
- Precisão prática
- Contexto-dependente

“Historicamente, maçãs caem”

Ambas são formas válidas de conhecimento científico

Hibridização: O Melhor dos Dois Mundos



Exemplos

- Neural ODEs com estrutura hamiltoniana
- PINNs para problemas inversos
- Graph Neural Networks para simulações físicas

Desafio da Interpretabilidade

Como tornar modelos de IA mais compreensíveis?

Princípios da Física:

- Leis de conservação
- Simetrias
- Localidade
- Causalidade

Aplicações em IA:

- Equivariant NNs
- Conservation laws constraints
- Causal representation learning
- Physics-guided architectures

A física como fonte de princípios reguladores para IA

O Futuro da Física na Era da IA

- ❶ **Descoberta assistida por IA**
 - Identificação de padrões em dados massivos
 - Sugestão de hipóteses a serem testadas
- ❷ **Simulação acelerada**
 - Emuladores neurais de simulações físicas
 - Exploração de espaços de parâmetros
- ❸ **Síntese de conhecimento**
 - Integração de dados heterogêneos
 - Conexões entre áreas distintas

O físico como integrador de paradigmas

A Permanente Relevância da Mecânica Clássica

Fundamento Conceitual

- Base de toda física moderna
- Linguagem matemática universal
- Paradigma de rigor científico
- Framework para novos desenvolvimentos

Relevância Contemporânea

- Engenharia e tecnologia
- Astrofísica e cosmologia
- Biofísica e sistemas complexos
- Inspiração para algoritmos

Mensagem Central

*A Mecânica Clássica não é obsoleta
— é fundamental e atemporal*

*“A mecânica de Newton é
ainda a física que mais se
usa.”*

— Feynman

Mecânica Clássica na Era Digital


Inspiração para IA

- Arquiteturas baseadas em física
- Princípios variacionais
- Leis de conservação
- Simetrias como inductive bias

Benchmark para IA

- Validação de modelos
- Ground truth analítico
- Teste de extrapolação
- Avaliação de interpretabilidade

A Mecânica Clássica como pedra de toque para a era da IA



Diferentes formas de conhecimento não são
excludentes

A ciência avança pela pluralidade metodológica

O físico contemporâneo: integrador de paradigmas

A Mecânica Clássica permanece relevante não *apesar* da IA, mas *junto* com ela —
como instrumento complementar na busca pela compreensão da natureza.

Obrigado

Perguntas?

“O objetivo da física é descobrir as leis que a natureza escolheu, não as leis que nós gostaríamos que ela tivesse escolhido.”

— Richard Feynman

Mecânica Clássica

- GOLDSTEIN, H. *Classical Mechanics*. 2nd ed. Addison Wesley, 2002.
- LANDAU, L. D.; LIFSHITZ, E. M. *Mechanics*. 3rd ed. Butterworth-Heinemann, 1976.
- ARNOLD, V. I. *Mathematical Methods of Classical Mechanics*. Springer, 1989.

Referências Seleccionadas II

IA e Aprendizado de Máquina

- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- VASWANI, A. et al. Attention Is All You Need. *NeurIPS*, 2017.

Conexões Física-IA

- KARNIADAKIS, G. E. et al. Physics-informed machine learning. *Nature Reviews Physics*, v. 3, p. 422-440, 2021.
- BRUNTON, S. L. et al. Discovering governing equations from data. *PNAS*, v. 113, n. 15, p. 3932-3937, 2016.
- FRISTON, K. et al. The free energy principle made simpler. *Physics Reports*, v. 1024, p. 1-29, 2023.
- CRANMER, M. D. et al. Lagrangian Neural Networks. *ICLR Workshop*, 2020.